

SEMANA DA FÍSICA 2026 • UEM • MINICURSO

MODELOS DE LINGUAGEM DE GRANDE ESCALA (LLM) NA FÍSICA

Da interpretação de dados experimentais à descoberta de conhecimento

Dr. Anuar Mincache




BREAKING NEWS

A IA MUDOU DE PAPEL.

Nos últimos anos, vimos uma grande mudança: da IA que reconhece padrões para a IA generativa, que cria, explica e propõe.

IA CLÁSSICA RECONHECE PADRÕES

Aprende a partir de exemplos e identifica o que já existe.



2022 → 2026

DE
“QUAL É
O PADRÃO?”
PARA
“O QUE PODEMOS
CRIAR COM ELE?”

IA GENERATIVA (LLMs) GERA E CONSTRÓI

Aprende padrões da linguagem e de dados e produz conteúdo novo.



Isso é apenas uma IA melhor ou estamos diante de uma **ferramenta científica diferente?**




UEM

DEPARTAMENTO DE FÍSICA

O que muda quando a máquina aprende com os dados?


1 Antes

Observar → propor
uma equação → testar.



2 Agora

A IA encontra o padrão
nos dados.



3 O físico decide

Escolhe o que medir,
o que entra no modelo,
e o que merece ser acreditado.



Aprender com dados: o que ML realmente faz

Antes das redes profundas e dos robôs de laboratório,
uma ideia só: encontrar uma função que liga o que você
mede ao que você quer saber.

**Tudo o mais é variação de sofisticação —
e de risco.**

Machine learning é ajuste de função


— com esteroides

A ideia é a mesma: encontrar uma função que transforma as entradas (x) no que queremos prever (y). O que muda é a complexidade da função.

Regressão linear

(2 parâmetros)

$$y = ax + b$$




Encontra a melhor reta que passa pelos dados.

Modelos modernos

(milhões de parâmetros)

$$y = f(x) + \varepsilon$$



Aprende uma função flexível o bastante para se ajustar a padrões complexos.



Por que isso importa?



Captura relações mais complexas

Funciona mesmo quando o padrão não é uma reta.



Revela correlações úteis

Encontra relações entre muitas variáveis que seriam difíceis de ver.



Mas não substitui a física

Um modelo pode prever, por exemplo, o % de Nd sem "saber" que se trata de um pico de Bragg. Só a física diz se o padrão faz sentido causal.

Supervisionado, não supervisionado, por reforço


Três formas de aprender, três objetivos diferentes.

01

Supervisionado

Aprender com gabarito

Usa dados rotulados para prever o resultado correto.



Exemplo


A partir do difratograma, prever o % de Nd ou a fase cristalina do material.

02

Não supervisionado

Achar estrutura sem gabarito

Não existe resposta certa. O algoritmo agrupa, separa e encontra padrões.



Exemplo

Separar fases misturadas num mapa de difração ou encontrar famílias de espectros sem rótulos.

03

Por reforço

Aprender agindo

O agente tenta, observa o resultado e recebe uma recompensa.



Exemplo

Ajustar parâmetros do tokamak para manter o plasma estável ou otimizar o feixe em aceleradores.


Os modelos que a física abraçou

Quatro famílias de modelos para descrever a matéria e seus fenômenos.

01

Modelos de materiais

Como os átomos se organizam e interagem.



Exemplo

Estrutura cristalina do $\text{Nd}_2\text{Fe}_{14}\text{B}$.

02

Modelos de matéria condensada

Propriedades coletivas: elétrons, magnons, fônons.



Exemplo

Bandas eletrônicas e transporte.

03

Modelos de instrumentação

Como o experimento mede e distorce o sinal.




Exemplo

Difratograma de raios X.

04

Modelos multiescala

Do elétron ao dispositivo, conectando escalas.




Exemplo

Da estrutura atômica à performance do ímã.

Rede neural: soma ponderada com **torção não linear**

Combina muitas variáveis e aprende padrões complexos nos dados.



O QUE FAZ UM NEURÔNIO?

Cada neurônio combina as entradas, aplica uma função não linear (torce o sinal) e passa o resultado adiante. Juntas, muitas camadas aproximam qualquer função.

Função de ativação (ex.: ReLU)




POR QUE É "PROFUNDA"?

Cada camada aprende representações mais abstratas: picos → fases → correlações → composição. Isso permite lidar com muitos dados, ruído e relações não lineares que um modelo simples não captura.

PINN: colocar a lei física dentro da função de perda

A rede aprende com os dados e respeita a física ao mesmo tempo.



$$\mathcal{L} = \underbrace{\mathcal{L}_{\text{dados}}}_{\text{ajusta aos dados medidos}} + \lambda \underbrace{\mathcal{L}_{\text{física}}}_{\text{penaliza quando viola a lei da física}}$$



Â IDEIA

A rede é penalizada duas vezes:

- 1 quando erra os dados medidos
- 2 quando viola a equação da física (ex.: conservação de energia, Navier-Stokes)



POR QUE IMPORTA?

- ✓ Funciona com poucos dados
- ✓ Evita soluções não físicas
- ✓ O modelo serve à física, não o contrário.

Exemplo ilustrativo: 14 pontos com ruído. A rede livre (vermelho) diverge das amostras; o PINN (verde) mantém a solução no espaço das soluções físicas.

IA generativa: propor estruturas que ninguém sintetizou

Modelos generativos aprendem a distribuição dos dados e criam candidatos realistas para novas estruturas.

O QUE FAZEM?



VAEs

Representação compacta da estrutura cristalina



GANs

Gera novas estruturas realistas



Modelos de difusão

Aprende a distribuição e amostra novos materiais



Candidatos


novas estruturas cristalinas e moléculas

NA FÍSICA DE MATERIAIS

1

Aprender

dados conhecidos de estruturas



2

Gerar


novos candidatos realistas



3

Validar

com cálculo DFT e experimentos



FLUXO DE DESCOBERTA



Dados estruturais



Modelo generativo



Candidatos novos




DFT + filtros



Estruturas promissoras

EXEMPLO DO NOSSO CURSO

Geramos 125 difratogramas sintéticos ("ecos" das 5 amostras) e o R^2 subiu para 0,945. O modelo aprendeu a variação e não decorou o ruído.



LIÇÃO

Dado sintético serve para pré-treinar, testar ideias e expandir o espaço de soluções. A validação (DFT/experimento) continua essencial.

IA dentro do ciclo experimental


Da medida à síntese: a IA participa de todas as etapas.

03



O que fizemos à mão, a literatura já faz com IA


Mesmo princípio físico. Agora em escala: milhares de padrões, sem intervenção manual.



1

Pré-processamento com IA


Remove fundo, reduz ruído e alinha os padrões.



2

Identificação de fases


Classifica padrões e sugere as fases mais prováveis.



3

Refinamento assistido

Busca automática de parâmetros (ex.: Rietveld) e avaliação rápida de modelos alternativos.



Mesma física

posições, larguras, intensidades.



Muito mais dados

milhares de padrões em vez de poucos.



Resultado

identificação mais rápida, modelos melhores.




IA não substitui a física

ela automatiza e escala o que já sabemos fazer.


O ciclo que não dorme: medir, aprender, propor de novo

Um laboratório autônomo que fecha o ciclo continuamente, gerando novas descobertas.



OTIMIZAÇÃO BAYESIANA

A cada ciclo, o modelo estima onde a resposta é mais incerta ou mais promissora e escolhe o próximo experimento. Mede-se menos e aprende-se mais rápido do que varrendo uma grade cega de composições.



JÁ EXISTE DE VERDADE

Plataformas autônomas em Berkeley (A-Lab) e outros centros já sintetizam e medem materiais novos com intervenção humana mínima, reportadas na literatura de 2023 em diante.



O QUE NÃO AUTOMATIZA

A pergunta científica, o critério de sucesso e o ceticismo sobre o resultado — isso continua humano.



- Definir o problema
- Validar resultados
- Tomar decisões
- Contexto físico e aplicação



Funciona 24/7

Fecha o ciclo sem parar.



Gera mais dados

Milhares de amostras de forma eficiente.



Descobre mais rápido

Encontra composições e estruturas promissoras.



Complementa o cientista

Amplia a intuição e reduz tempo e custo.

Triagem computacional: o funil antes do tubo de ensaio

A IA explora milhões de possibilidades e seleciona poucas, mas promissoras, para serem testadas em laboratório.



2,2 milhões
estruturas cristalinas candidatas

Propostas pela GNoME (DeepMind, Nature 2023) a partir de busca orientada por IA.



380 mil
previstas como estáveis

Selecionadas por cálculos de primeiros princípios (DFT), com propriedades físicas estimadas.



> 150 mil
no Materials Project

Materiais computados e disponibilizados em um banco público que já alimenta modelos de IA do mundo inteiro.



O FUNIL: DA IDEIA AO MATERIAL REAL



IA propõe candidatos
espaço químico quase infinito



DFT confirma estabilidade
propriedades estimadas



Síntese em robô/laboratório
poucos candidatos



DRX verifica
o que foi prometido existe de verdade?



E ONDE O CURSO SE ENCAIXA?

Na última etapa do funil: verificar por difração o que a previsão prometeu. Como os padrões de difração não são lidos diretamente pela máquina, começamos pelos métodos clássicos (Bragg e Scherrer), e não por Python.

LLMs: o copiloto que não calcula

O modelo de linguagem que ajudou vocês a escrever o notebook não é um físico nem uma calculadora. Ele é um assistente que entende linguagem, organiza ideias e acelera o trabalho.

O QUE ELE NÃO É

- ✗ Não tem intuição física.
- ✗ Não faz cálculos exatos.
- ✗ Não executa experimentos.
- ✗ Pode inventar referências.
- ✗ Pode cometer erros de lógica.



Sempre valide resultados importantes (cálculos, dados, interpretações) com os seus conhecimentos e fontes confiáveis.

O QUE ELE É



Lê e resume literatura



Explica conceitos



Escreve e organiza código



Sugere análises



Ajuda a depurar erros



Planeja experimentos



Usa o seu conhecimento para ser útil

COMO TRABALHAR COM ELE

1

Dê contexto claro

Explique o objetivo, forneça dados e defina o formato da resposta.

2

Peça passos

Solicite raciocínio passo a passo.

3

Verifique e valide

Cheque cálculos, resultados e referências.

4

Itere

Peça ajustes e explore alternativas.

5

Use como parceiro

Para gerar ideias, planejar, organizar e acelerar o seu trabalho.



Economiza tempo

na escrita, análise e organização de ideias.



Conecta áreas

relaciona conceitos e fontes rapidamente.



Aumenta a produtividade

em notas, relatórios, códigos e apresentações.



Amplia a criatividade

sugere abordagens e novos experimentos.

O que delegar ao LLM — e o que **nunca delegar**

Use o LLM como um multiplicador de produtividade, mantendo o papel de cientista.

PODE DELEGAR – COM REVISÃO

Tarefas que o LLM faz muito bem, mas você sempre revisa.



Escrever e depurar código

Gera notebooks, funções e scripts. Você executa e verifica cada célula.



Explicar conceitos e erros

Traduz linguagem técnica, explica ideias e interpreta traceback de forma clara.



Resumir e mapear literatura

Sintetiza artigos, compara resultados e organiza referências (com verificação por você).



Traduzir jargão

Do artigo para o aluno, do aluno para o artigo, mantendo o sentido técnico.

Tarefas
que podem
ser delegadas



Tarefas
que nunca
devem ser
delegadas



Você revisa, valida
e decide.

NUNCA DELEGAR

Tarefas que exigem seu julgamento científico e responsabilidade.



Números do artigo

Todo valor vem de uma célula de cálculo, com unidade e incerteza corretas.



Referências bibliográficas

Ele pode sugerir, mas você confere e formata corretamente (ABNT).



Interpretação física final

“O Nd contraiu a rede” é uma afirmação sua, baseada nos dados e no conhecimento físico.



Decidir se o resultado é publicável

Isso exige visão crítica, contexto, viés e responsabilidade — não se terceiriza.

REGRA PRÁTICA DO CURSO



1. O LLM propõe caminhos e escreve rascunhos



2. Você executa no Python e verifica os resultados



3. Analisa pela física e pelo bom senso



4. Decide, revisa e transforma no seu trabalho

Overfitting: toda IA pega; só a validação cura

O modelo aprende o “ruído” do treino, mas isso não se repete em dados novos.

1 ERRO NO TREINO


Sempre diminui conforme o modelo fica mais complexo. O modelo pode “memorizar” os dados e quase zerar o erro.

2 ERRO NA VALIDAÇÃO

Diminui no início (o modelo aprende o padrão), mas depois volta a subir (o modelo começa a aprender o ruído).

3 PONTO ÓTIMO

A menor erro de validação indica o modelo que generaliza melhor: aprende o padrão sem decorar o ruído.



O QUE ACONTECE NA PRÁTICA?

Modelo simples (underfitting)



Não consegue capturar o padrão (real).

Modelo adequado (generaliza bem)



Aprende o padrão e funciona para dados novos.

Modelo complexo (overfitting)



Passa por (quase) todos os pontos do treino, mas falha em dados novos.



Sintoma universal

O erro de treino sempre cai com a complexidade.



A validação é a vacina

Usamos dados que o modelo nunca viu para detectar o overfitting.



Escolha o ponto ótimo

Menor erro de validação (o melhor compromisso entre vies e variância).



Regra prática

$n = 5$, $p = 13$: o overfitting não é risco — é destino sem validação rigorosa.

5 perguntas para qualquer artigo de “IA + Física”

Use estas perguntas para avaliar resultados, evitar conclusões exageradas e entender o que realmente o trabalho mostra.

01

De onde vieram os dados?

Quantos experimentos reais e quantos sintéticos?

Saiba a origem, o tamanho e a qualidade dos dados. Simulação não é medição — modelos treinados só com dados sintéticos podem não representar a complexidade do mundo real.



Dados experimentais

→ incluem ruído real, imperfeições, condições de laboratório.



Dados sintéticos

→ úteis para treinar, mas podem não cobrir todas as situações reais.

02

O teste é realmente cego?

As amostras do mesmo experimento/lote podem estar nas duas pontas?

Verifique se a separação entre treino e teste evita “vazamento de dados”. Dados do mesmo experimento, lote ou amostra não podem estar ao mesmo tempo no treino e na validação.

Separação correta

Amostras diferentes no treino e no teste



Vazamento de dados

Mesma amostra/lote no treino e no teste




03

Qual é a régua?

$R^2 = 0,9$ impressiona, mas compare com a régua trivial.

Sempre compare com um modelo simples de referência (ex.: média, ajuste linear). No nosso exemplo, a média deu $R^2 \approx -0,56$ no LOO, enquanto o modelo chegou a $R^2 \approx 0,90$ — isso mostra que o modelo realmente aprendeu um padrão relevante e não apenas “memoriza” a média.



04

A física fecha?

Unidades, limites assintóticos, simetrias.

Verifique se o resultado respeita o conhecimento físico conhecido. A previsão deve se comportar corretamente fora do intervalo de treino, respeitar unidades, limites teóricos e simetrias do sistema.



Unidades consistentes



Limites assintóticos



Simetrias do sistema




Comportamento fora do intervalo de treino

05

O que o modelo adiciona?

Um modelo simples já resolve?

Se um modelo simples com poucas variáveis já explica bem os dados, uma rede profunda pode ser desnecessária. Avalie o ganho real, a interpretabilidade e o custo (dados, tempo, energia, complexidade).



IDEIA PRINCIPAL

Boa IA em Física não é só alto R^2 . É resultado que faz sentido, generaliza, respeita a física e foi validado de forma rigorosa.

A IA não substitui o físico — desloca onde ele é raro

A IA não faz a física por você. Ela amplia a sua capacidade de enxergar, interpretar e conectar dados com conhecimento.

FÍSICA



- Bragg, Scherrer, Williamson–Hall: sem IA, o difratograma é apenas picos e ruído.
- A teoria (modelo físico) transforma a medida em conhecimento: fases, parâmetros de rede, tensões, tamanho de cristalito, defeitos etc.



CÓDIGO



- Python é o instrumento de bancada digital.
- Você programa para ler dados, tratar ruído, ajustar modelos, comparar resultados e controlar o fluxo de análise.
- A IA acelera a escrita do código, sugere funções e ajuda a depurar erros.

EXPERIMENTO

O difratômetro mede (dados com ruído)



FÍSICA
modelo e interpretação

ESTATÍSTICA
incertezas e significância

CÓDIGO
implementa e automatiza

CETICISMO
valida e questiona

ESTATÍSTICA



- Dados experimentais são sempre “imperfeitos”.
- Flutuações aleatórias descrevem-se por distribuições (ex.: Poisson, n pequeno).
- Com estatística avaliamos se o resultado é confiável, estimamos incertezas e evitamos conclusões exageradas.

CETICISMO



- A IA não tem intuição física nem senso crítico.
- Ela pode gerar resultados “bonitos, mas errados”.
- Cabe ao físico questionar: faz sentido? é consistente com a teoria? é publicável?
- Quanto melhores as ferramentas, mais importante fica o julgamento humano.

COMO TUDO SE CONECTA



Dados do difratômetro (reais, com ruído)



Código (Python) trata e ajusta




IA sugere, organiza, acelera



Modelo físico extrai parâmetros e interpreta



Estatística estima incertezas e testa hipóteses



Resultado final conhecimento útil e publicável



IDEIA CENTRAL

O difratômetro mede, a rede propõe, o LLM (IA) redige e organiza, **mas a cadeia inteira depende de alguém que entenda os quatro elementos.** Esse alguém é o físico que este curso começou a formar.

A REGRA DE OURO – AGORA EM DOBRO

"Se o número não saiu de uma **célula de cálculo, ele não entra no artigo — nem quando a frase do LLM estiver convincente."**

A máquina aprende padrões; a física decide quais padrões são conhecimento.
Bem-vindos à era em que as duas coisas trabalham juntas.

IA (LLM)

Enxerga padrões e linguagem



- Organiza informações
- Sugere hipóteses
- Escreve e resume
- Ajuda no código
- Acelera a análise

Não mede, não garante e não substitui o raciocínio físico.



**JUNTAS
AMPLIAM O
CONHECIMENTO**



FÍSICA

Decide o que é real e significativo




- Define o modelo
- Impõe leis e simetrias
- Valida resultados
- Interpreta o significado
- Diz o que é publicável

Fornece os critérios, os limites e o sentido físico.



O difratômetro mede, a rede propõe, o LLM redige. A cadeia inteira depende de alguém que entenda os quatro elementos — **esse alguém é o físico que este curso começou a formar.**



Obrigado pela sua atenção!